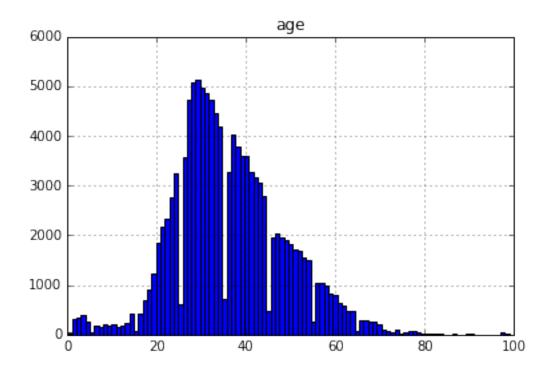
HW04 Age Kulikov

May 17, 2016

1 Linear Regression + k-means - Age prediction

1.1 Kulikov Alex, gr. 397

```
In [2]: import numpy as np
        import pandas as pd
       from sklearn.linear_model import LinearRegression
       from sklearn.cross_validation import cross_val_score
       from sklearn.feature_extraction.text import HashingVectorizer
       %pylab inline
        %load_ext autoreload
        %autoreload 2
       from IPython.core.display import HTML
       HTML("<style>.container { width:90% !important; }</style>")
Populating the interactive namespace from numpy and matplotlib
The autoreload extension is already loaded. To reload it, use:
  %reload_ext autoreload
Out[2]: <IPython.core.display.HTML object>
1.2
     Data analysis
1.2.1 age
In [3]: age_train_df = pd.read_csv('kaggle_data/age_profile_train', header=None, delimiter='\t')
        age_train_df.columns = ['id', 'age']
In [4]: age_train_df.head()
Out [4]:
                                             age
       0 00000013CB5719C0000A2C90002C101
        1 00000001442BE24000001B7D00F50801
       2 00000001448580F800003F1B31FB0901
       3 0000000145BDB2FF000157971645E901
        4 000000014602771F0000DB9359714C01
                                              48
In [5]: age_train_df.hist(column="age", bins=100)
Out[5]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x7fa8ca595390>]], dtype=object)
```



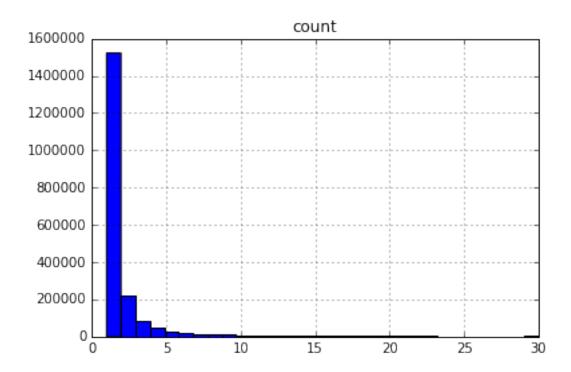
1.2.2 urls

In [7]: urls_train_df.head()

count	url	id	Out[7]:
1	login.rutracker.org	000000014B60815F65B38258011B6C01	
4	rutracker.org	000000014B60815F65B38258011B6C01	
1	admin.tour-spb.net	000000014C03DA2A47AC433A0C755201	
1	czinfo.ru	000000014C03DA2A47AC433A0C755201	
1	forumsostav.ru	000000014C03DA2A47AC433A0C755201	

In [8]: urls_train_df.hist(column="count", bins=30)

Out[8]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x7fa8c5bb3690>]], dtype=object)



For this time, we omit the "count" column

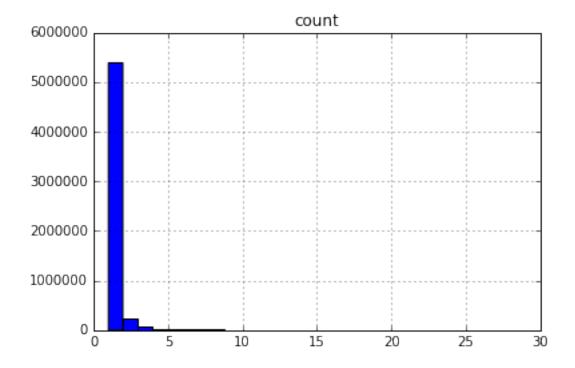
In [13]: titles_train_df.head()

```
In [9]: urls_train_df = pd.DataFrame(urls_train_df.groupby('id')['url'].apply(lambda x: x.tolist()))
       urls_train_df['id'] = urls_train_df.index
       urls_train_df.index = range(len(urls_train_df))
       urls_train_df.columns = ['urls', 'id']
In [10]: urls_train_df.head()
Out [10]:
                                                         urls \
                      [id.rambler.ru, mail.rambler.ru, r0.ru]
         1
           [1prime.ru, autorambler.ru, chellak.ru, docs.c...
         2
                                           [bosch-korolev.ru]
         3 [aptekanizkihcen.ua, colady.ru, gorod.dp.ua, i...
            [astrorok.ru, diets.ru, edaplus.info, eshzdoro...
                                          id
          000000013CB5719C0000A2C90002C101
           00000001442BE24000001B7D00F50801
         2 00000001448580F800003F1B31FB0901
         3 0000000145BDB2FF000157971645E901
           000000014602771F0000DB9359714C01
1.2.3 titles
In [12]: titles_train_df = pd.read_csv('kaggle_data/title_unify_train', header=None, delimiter='\t')
         titles_train_df.columns = ['id', 'title', 'count']
```

```
Out[13]:
           000000014B6D41C13D777E8314725401
           0000000150707ACB8A82451C0307BC01
         2 0000000150707ACB8A82451C0307BC01
           0000000150707ACB8A82451C0307BC01
           0000000150707ACB8A82451C0307BC01
                                                        title count
        0
                                          коляна лента прикол
         1
                   candi410 rambler ru входящая рамблер-почта
                                                                   1
         2 cosmopolitan витамин волос для женщина журнал ...
                                                                   1
         3 realbox бокс для интернет-магазин страница тов...
                                                                   1
         4 realbox бокс для интернет-магазин товар экипир...
                                                                   2
```

In [14]: titles_train_df.hist(column="count", bins=30)

Out[14]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x7fa89ef113d0>]], dtype=object)



Here too

```
1 [24-х 34-х до договор неделя новость предложит...
         2 [авто бош контакт королёв сервис, авто бош кор...
         3 [иа втрать війни донбасі за на новини озвучить...
         4 [black walnut грецкий орех чёрный, inmoment ru...
        0 000000013CB5719C0000A2C90002C101
         1 00000001442BE24000001B7D00F50801
         2 00000001448580F800003F1B31FB0901
         3 0000000145BDB2FF000157971645E901
         4 000000014602771F0000DB9359714C01
1.2.4 merge it all!
In [17]: # train_df = urls_train_df.merge(age_train_df, on='id', how='left') # to start, we'll consider
         # train_df = titles_train_df.merge(age_train_df, on='id', how='left')
         train_df = urls_train_df.merge(titles_train_df.merge(age_train_df, on='id', how='inner'), on=':
In [18]: train_df.head()
Out[18]:
                                                         urls \
                      [id.rambler.ru, mail.rambler.ru, r0.ru]
         1 [1prime.ru, autorambler.ru, chellak.ru, docs.c...
                                           [bosch-korolev.ru]
         3 [aptekanizkihcen.ua, colady.ru, gorod.dp.ua, i...
         4 [astrorok.ru, diets.ru, edaplus.info, eshzdoro...
        0 000000013CB5719C0000A2C90002C101
         1 00000001442BE24000001B7D00F50801
        2 00000001448580F800003F1B31FB0901
         3 0000000145BDB2FF000157971645E901
         4 000000014602771F0000DB9359714C01
                                                       titles age
        0 [бесплатный надёжный почта рамблер электронный...
                                                                53
         1 [24-х 34-х до договор неделя новость предложит...
         2 [авто бош контакт королёв сервис, авто бош кор...
                                                                28
         3 [иа втрать війни донбасі за на новини озвучить...
                                                                44
         4 [black walnut грецкий орех чёрный, inmoment ru...
                                                                48
In [19]: print(train_df.shape)
        print(type(train_df))
(114090, 4)
<class 'pandas.core.frame.DataFrame'>
     Relabeling data into groups
In [20]: train_df['label'] = pd.Series(np.zeros(train_df.shape[0]), index=train_df.index)
In [21]: X_train, y_train = train_df.loc[:, ["urls", "titles"]], train_df.loc[:, ["age"]]
In [22]: print(y_train)
        print(type(y_train))
```

3.00	
age 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29	53 48 28 44 48 36 33 41 51 32 29 36 35 37 31 34 24 34 19 40 39 43 27 26 33 51 48 23 27
114060 114061 114062 114063 114064 114065 114066 114067 114068 114070 114071 114072 114073 114074 114075 114076 114077 114078 114079 114080 114081	44 44 39 42 39 6 50 30 40 29 29 31 33 26 20 24 51 28 41 46 58 31

```
114082
         32
114083
         44
114084
         34
114085
         34
114086
         26
114087
         58
114088
         56
114089
         31
[114090 rows x 1 columns]
<class 'pandas.core.frame.DataFrame'>
In [23]: train_df.set_value(y_train[y_train["age"].isin(range(0, 27))].index, "label", 1)
         train_df.set_value(y_train[y_train["age"].isin(range(27, 31))].index, "label", 2)
         train_df.set_value(y_train[y_train["age"].isin(range(31, 35))].index, "label", 3)
         train_df.set_value(y_train[y_train["age"].isin(range(35, 41))].index, "label", 4)
         train_df.set_value(y_train[y_train["age"].isin(range(41, 49))].index, "label", 5)
         train_df.set_value(y_train[y_train["age"] > 49].index, "label", 6)
Out [23]:
                                                                urls
         0
                            [id.rambler.ru, mail.rambler.ru, r0.ru]
         1
                 [1prime.ru, autorambler.ru, chellak.ru, docs.c...
         2
                                                  [bosch-korolev.ru]
         3
                 [aptekanizkihcen.ua, colady.ru, gorod.dp.ua, i...
         4
                 [astrorok.ru, diets.ru, edaplus.info, eshzdoro...
         5
                 [agroru.com, donupak.ru, meteonova.ru, rus-map...
         6
                 [9tv.co.il, katalogturbaz.ru, nanotara.ru, ofi...
         7
                              [arbitr.ru, consultant.ru, utexco.ru]
         8
                 [1tv.ru, arhinovosti.ru, bilettorg.ru, dev.diz...
         9
                 [bibliotekar.ru, casinoaltair.com, expertiza34...
         10
                 [bettingexpert.com, carexpo.ru, chelsea-fc.ru,...
         11
                 [aif.ru, business-lady.com, calorizator.ru, ce...
         12
                 [1prime.ru, dr-krupnik.ru, mirtesen.ru, ria.ru...
         13
                                                    [championat.com]
         14
                                       [7fon.ru, ru.motorsport.com]
         15
                                                    [voronezh.hh.ru]
         16
                 [afisha.ru, altagro22.ru, asfera.info, barnaul...
         17
                              [agbz.ru, atmagro.ru, moyareklama.by]
         18
                 [1245.ru, aeroflot.ru, afy.ru, akwarium.su, aq...
         19
                 [picantecooking.com, povarenok.ru, rabbit.ru, ...
         20
                                     [inf.reshuoge.ru, reshuoge.ru]
         21
                 [kommersant.ru, m.aeroflot.ru, m.gq.ru, miss-t...
         22
                 [aptekamos.ru, assessor.ru, buhonline.ru, drom...
         23
                                                           [vota.ru]
         24
                                                         [altstu.ru]
         25
                                                         [tvrain.ru]
         26
                                       [takabo.ru, vladkomfort.com]
         27
                     [proshkolu.ru, studresearsh.ru, vashaspina.ru]
         28
                 [bytovaya-tekhnika.taganrog.mnogonado.net, tag...
         29
                             [inf.reshuege.ru, vm.ru, whoswhos.org]
                 [kirby-russia.tiu.ru, mail.rambler.ru, pevp.mo...
         114060
         114061
                 [mail.rambler.ru, news.rambler.ru, online777sl...
                 [1gb.ru, airsteps.ru, eda.ru, gotovim.ru, job-...
         114062
                 [i.ovkuse.ru, mail.rambler.ru, osd.ru, pevp.mo...
```

114063

```
[aif.ru, finance.rambler.ru, mail.rambler.ru, ...
114064
114065
        [gotovim-doma.ru, id.rambler.ru, mail.rambler...
114066
        [dachadecor.ru, humangarden.ru, 12announce.ru,...
114067
        [chadorado.ru, family.rambler.ru, krasnodar.ir...
114068
          [baby-52.ru, fundamenti-v-spb.ru, pesnifilm.ru]
114069
        [formulalubvi.com, kino-teatr.ru, mail.rambler...
114070
        [ac-mzsa.ru, autodoc.ru, avtotsentry.smolensk...
114071
                              [allnum.ru, mail.rambler.ru]
114072
        [drivers.mydiv.net, drp.su, hotdownloads.ru, m...
114073
        [almaxavto.com.ua, avtorynok.com.ua, exist.ru,...
114074
        [babylonvape.ru, gdzometr.ru, id.rambler.ru, m...
114075
                [mail.rambler.ru, noffery.ru, rambler.ru]
114076
        [forum.ribca.net, rubo.ru, top.mail.ru, top100...
114077
        [consultant.ru, estatelatvia.com, god-2016.com...
114078
        [bagforlife.ru, bellore.ru, blondie.ru, brjune...
114079
        [autoplus.su, euroauto.ru, xn--2111-43da1a8c.x...
114080
                  [kino-teatr.ru, knijky.ru, zak.depo.ua]
114081
        [m.rambler.ru, m.rns.online, m.weekend.rambler...
114082
                         [mail-pda.rambler.ru, pozdrav.ru]
114083
                                               [lady74.ru]
114084
        [art-med.ru, khablyalya.ru, pregnant-club.ru, ...
114085
        [afisha.ru, exist.ru, inmoment.ru, kiev.vgorod...
        [cosmo.ru, pda.ura.ru, podoprigora74.livejourn...
114086
114087
        [aif.ru, autochel.ru, chelyabinsk.ru, id.rambl...
114088
                    [blog.partisani.ge, li.ru, tvrain.ru]
114089
        [doctorkirov.ru, drive.ru, extrim-park43.ru, m...
                                       id
0
        000000013CB5719C0000A2C90002C101
1
        00000001442BE24000001B7D00F50801
2
        00000001448580F800003F1B31FB0901
3
        0000000145BDB2FF000157971645E901
4
        000000014602771F0000DB9359714C01
5
        0000000147B2D6F311DB5C4201B7FB01
6
        0000000147C68954150168D701A8B801
7
        0000000147EB76D738CD80750C879701
8
        00000001482AAFB69FA5228008AC2A01
9
        0000000148390BB56A6B22BB178D3901
10
        00000001487DAF8D69CD43E416D6AD01
11
        0000000148AC192341E3BDAD0B95DE01
12
        0000000148C2B61B70F8651309287201
13
        0000000148DB999352D9CAF309511101
14
        0000000148EB77A2435E76A711E38B01
15
        0000000148F786727740B36700E82101
16
        0000000148FD5BA0B553811202AB4601
17
        0000000148FF6AFB2A2183F50311A901
18
        00000001490B9AF7989CCE8E026C2901
19
        00000001490C03CD81C3F77D03591501
20
        000000014917C91E88E90DC90A3B9D01
21
        000000014919555188E90DC90FF8E401
22
        00000001491A894285610DC813C50E01
23
        000000014929641F66F6C0110E62C401
24
        000000014947912B3F44BA2C032EB701
25
        00000001494E5DE0241913C9184EBF01
```

26 27 28 29	00000001494FA563241913C91D6FA201 00000001495B2BC55C0079021B37AD01 00000001496318EB3F650D200EB00101 00000001496C4195AD4C674803C9B501		
114060	06393B87570260BC00000543F588B501		
114061	06393B87570270DC00006DAC93F56F01		
114062	06393B8757027C0C00006DE991DD9101		
114063	06393B8757029A140000053DF5A87A01		
114064	06393B8757034DB20000518C41942C01		
114065	06393B875705208E0000054E2A852C01		
114066	06393BC156F59CF100000533F051B801		
114067	06393C8956F8F1B600006DBECC09A701		
114068	06393D0556F3D2510000053CCC1E9501		
114069	06393D555700FE8A00006E0D72071401		
114070	06393DC056F6C1CC000004E57E05A001		
114071	06393E1656FF91D4000051CCF0D13C01		
114072	06393E7D56F67A6F000005489A814C01		
114073	06393FF656FB75860000054780A8EE01		
114074	0639434C56FE7EBA000005403C284E01		
114075	0639452A570504200000055527E56F01		
114076	063945575700ED290000054ECF865F01		
114077	6B9BD7D94D7F3767F8CD695D77FA6E77		
114078	77F8BDE14D77F99E9E6773F7EB9EE7E1		
114079	795E97E747DB38B7B9C67F9A771F8E77		
114080	7DF577774777BDFDBA7EEF9F77F6C6D7		
114081	D374CD7D56E7359F5B7E6F9F7B3D6DDF		
114082	D79FBED94DD35ED75AADEDBC6D1CAFE7		
114083	DB399FE347F77B6DB566DB1FD136DF73		
114084	E736D7D34EF71D8FB46D6BDD6F9CADD1		
114085	E7DB77EB4EEFF6C73DD7EB5CD37CB7E3		
114086	E7DFB7DB4DDF3C7E785EDF7DF17AA76D		
114087	E9B9D7D347EB1ACE5AAEEBFCE3FBCE7B		
114088	EBFAC66B4EE3FB96BA5DD7DDE3787FE7		
114089	F537AD6B46D31ABFF597EFDFE1BDDE71		
	titles	200	label
0	[бесплатный надёжный почта рамблер электронный	age 53	faber 6
1	[24-х 34-х до договор неделя новость предложит	48	5
2	[авто бош контакт королёв сервис, авто бош кор	28	2
3	[иа втрать війни донбасі за на новини озвучить	44	5
4	[black walnut грецкий орех чёрный, inmoment ru	48	5
5	[апрель год день март месяц на неделя от погод	36	4
6	[rankw ru tovar хох хох-tovar анализ доход ком	33	3
7	[возможность госзакупка консультант малое плюс	41	5
8	[13d билет заказать имя купить на спектакль те	51	6
9	[1-метр velol александр альберто арно велоспор	32	3
10	[1vitali1 ii мафра от порту санинга токио фк ц	29	2
11	[caloriz ru www диета курица модный на похуден	36	4
12	[plc powerlin адаптер, агентство азербайджан и	35	4
13	[матч новость премьер-лига расписание россия р	37	4
14	[window бесплатно для живой на обои рабочий ск	37	4
15	[оплата услуга]	31	3
16	[png psd бесплатно для клипарта мультяшки на п	34	3
	- · ·		

```
17
        [by moyareklama гомель купить на овца, агропро...
                                                             24
18
                                                             34
                                                                      3
        [06м 10х1 art daphn винить каталог коллекция к...
19
        [chow mein picantecook китайский курица лапша ...
                                                             19
20
                                                             40
        [гущина дмитрия задание информатика обучать ог...
                                                                      4
21
        [gq администратор блог ваш журнал лори любимый...
                                                             39
                                                                      4
22
                                                             43
        [2мл 50мг для инъекция купить мл раствор трама...
                                                                      5
23
        [4g yota безлимитный весь интернет мобильный м...
                                                             27
24
                                                             26
        [алтгту, алтгту занятие расписание, алтгту отд...
                                                                      1
25
        [авторизация дождь телеканал, восстановление д...
                                                             33
                                                                      3
26
                                                             51
                                                                      6
        [dr mosreg ru takabo uslugi zdrav врач запись ...
27
        [almag алмаг аппарат инструкция отзыв по приме...
                                                                      5
28
                                                             23
        [вред её капуста ламинария морской она польза ...
                                                                      1
29
        [вечерний жизнь зощенко из интересный михаил м...
                                                             27
                                                                      2
        [footer, ridzip ru аксессуар бытовой запчасть ...
                                                             44
114060
                                                                      5
114061
        [columbu автомат игровой онлайн отправляться п...
                                                             44
                                                                      5
                                                             39
                                                                      4
114062
        [air airstep id nike yeezi каталог кроссовок ч...
114063
        [footer, prodport ru консервы масло молоко мяс...
                                                             42
        [footer, аргумент биатлонист бьорндален вид до...
                                                             39
114064
                                                                      4
                                                              6
114065
        [co rambler авторизация, footer, бесплатный на...
                                                                      1
114066
        [adrenalin bot 12walker lineag top, battlestar...
                                                             50
                                                                      6
        [a7398h plai-doh принцесса софия церемония чай...
                                                                      2
114067
                                                             40
114068
        [беременность весь для заботливый мама она пор...
                                                                      4
        [hello russia встретить метро можно москва сно...
                                                             29
                                                                      2
114069
                                                             29
                                                                      2
114070
        [2746agamvw1b guardian автодок интернет-магази...
114071
        [lenta ru sivkova-elena входящая рамблер-почта...
                                                             31
                                                                      3
114072
        [crystal player pro window без бесплатно для к...
                                                             33
                                                                      3
                                                             26
114073
        [4a91 lancer mitsubishi для запчасть седан, al...
                                                                      1
                                                             20
114074
        [co rambler авторизация, nation ohm rda turbo ...
                                                                      1
114075
        [nofferi автомобиль автомобильный жидкий новый...
                                                             24
                                                                      1
                                                             51
114076
        [весь добавить каталог рейтинг сайт скриншот с...
                                                                      6
114077
        [glamour ru базовый весна-лето гардероб как но...
                                                             28
                                                                      2
114078
        [698308-fondent airstep cotto kultpokupki ru s...
                                                             41
                                                                      5
        [autoplu frontera opel su автомобиль автомобил...
                                                             46
                                                                      5
114079
                                                             58
114080
        [depo буковель красуня купальник на новини при...
                                                                      6
114081
        [new rambler servic бензин биржевой более выра...
                                                             31
                                                                      3
114082
                                               [март стих]
                                                             32
                                                                      3
114083
        [апрель год гороскоп для женский на телец, вес...
                                                             44
                                                                      5
        [арт-мёд беременность ветрянка вопрос на ответ...
                                                             34
                                                                      3
114084
                                                             34
        [chanel афиша киев магазин, cl merced для зажи...
                                                                      3
114085
        [cosmopolitan ведущий гламурный гузеев журнал ...
114086
114087
        [4z7616051a 4z7616051d 4z7616052a allroad arno...
                                                             58
                                                                      6
114088
        [ru онлайн попка порно секс, азербайджан военн...
                                                             56
                                                                      6
114089
        [5d merced-benz видео драйв комплектация отзыв...
                                                             31
                                                                      3
```

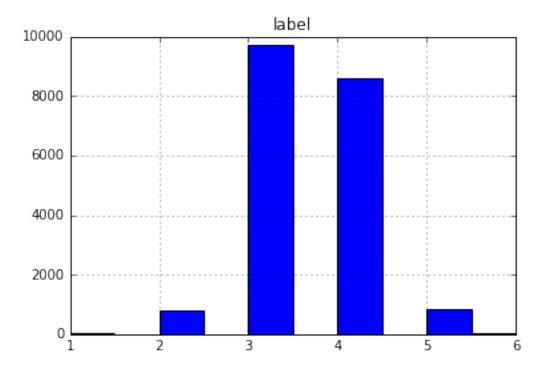
[114090 rows x 5 columns]

```
train_df.set_value(y_train[y_train["age"].isin(range(70, 80))].index, "label", 8)
        train_df.set_value(y_train[y_train["age"].isin(range(80, 90))].index, "label", 9)
        train_df.set_value(y_train[y_train["age"].isin(range(90, 100))].index, "label", 10)
In [24]: print(train_df[train_df["label"] == 0].shape)
(1863.5)
1.4 Getting test data
1.4.1 urls
In [25]: urls_test_df = pd.read_csv('kaggle_data/url_domain_test', header=None, delimiter='\t')
         urls_test_df.columns = ['id', 'url', 'count']
         urls_test_df = urls_test_df[['id', 'url']]
In [26]: urls_test_df = pd.DataFrame(urls_test_df.groupby('id')['url'].apply(lambda x: x.tolist()))
         urls_test_df['id'] = urls_test_df.index
         urls_test_df.index = range(len(urls_test_df))
         urls_test_df.columns = ['urls', 'id']
In [27]: urls_test_df.head()
Out [27]:
                                                         urls \
           [1000bankov.ru, 1tv.ru, 4put.ru, argumenti.ru,...
         1 [autorambler.ru, bilettorg.ru, dsol-druzhba.ru...
                                  [photosight.ru, rambler.ru]
         3 [base.consultant.ru, dogovor-obrazets.ru, fd.r...
         4 [assessor.ru, audit-it.ru, base.garant.ru, com...
         0 000000014A02348E701552980349FF01
         1 000000014A10EA183BF8594A0B2AB201
         2 000000014A4FE5C33A929D4C26943601
         3 000000014B7BB9957784A9BC0AC9F401
         4 000000014C7749F896D82C2B01E8B801
1.4.2 titles
In [28]: titles_test_df = pd.read_csv('kaggle_data/title_unify_train', header=None, delimiter='\t')
         titles_test_df.columns = ['id', 'title', 'count']
         titles_test_df = titles_test_df[['id', 'title']]
In [29]: titles_test_df = pd.DataFrame(titles_test_df.groupby('id')['title'].apply(lambda x: x.tolist())
         titles_test_df['id'] = titles_test_df.index
         titles_test_df.index = range(len(titles_test_df))
         titles_test_df.columns = ['titles', 'id']
In [30]: titles_test_df.head()
Out[30]:
                                                       titles \
         0 [бесплатный надёжный почта рамблер электронный...
         1 [24-х 34-х до договор неделя новость предложит...
         2 [авто бош контакт королёв сервис, авто бош кор...
         3 [иа втрать війни донбасі за на новини озвучить...
         4 [black walnut грецкий орех чёрный, inmoment ru...
```

```
0 000000013CB5719C0000A2C90002C101
         1 00000001442BE24000001B7D00F50801
         2 00000001448580F800003F1B31FB0901
         3 0000000145BDB2FF000157971645E901
         4 000000014602771F0000DB9359714C01
1.4.3 merge
In [31]: X_urls_test = urls_test_df.urls.values
         X_urls_test = map(lambda x: ' '.join(x), X_urls_test)
         %time hw = HashingVectorizer(n_features=1000).fit(X_urls_test)
         X_urls_test = hw.transform(X_urls_test).todense()
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 41 \mus
In [32]: print(X_urls_test.shape)
(19974, 1000)
     1st level – Linear Regression with 6 equal-sized buckets
In [33]: X_train_matrix, y_train = train_df.loc[:, ["urls"]].as_matrix(), train_df.loc[:, ["label"]]
         # print(X_train)
         \# X_train_matrix, y_train = train_df.loc[:, ["urls", "titles"]].as_matrix(), <math>train_df.loc[:, ["urls", "titles"]]
         X_train = train_df.urls.values
         for index in range(X_train_matrix.shape[0]):
             X_train[index] = map(lambda x: ' '.join(x), X_train_matrix[index])[0]
         print(X_train)
         print(X_train.shape)
         print(type(X_train))
         %time hw = HashingVectorizer(n_features=1000)
         %time X_train = hw.transform(X_train)
         print(X_train.shape)
         print(y_train.shape)
['id.rambler.ru mail.rambler.ru r0.ru'
 '1prime.ru autorambler.ru chellak.ru docs.cntd.ru echo.msk.ru expert.ru finance.rambler.ru forbes.ru fo
 'bosch-korolev.ru' ...,
 'aif.ru autochel.ru chelyabinsk.ru id.rambler.ru khl.ru m.rambler.ru m.rsport.ru mail-pda.rambler.ru no
 'blog.partisani.ge li.ru tvrain.ru'
 'doctorkirov.ru drive.ru extrim-park43.ru m.regions.pulset.ru mail-pda.rambler.ru reso.ru sberbank.ru'
(114090,)
<type 'numpy.ndarray'>
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 15 \mus
CPU times: user 6.4 s, sys: 40 ms, total: 6.44 s
Wall time: 6.39 s
(114090, 1000)
(114090, 1)
In [34]: reg = LinearRegression()
         %time reg.fit(X_train, y_train)
```

CPU times: user 1.17 s, sys: 10 ms, total: 1.18 s

Wall time: 1.17 s



```
[mail.rambler.ru, mineral.ru, nalog.ru, nova.r...
5
6
       [101.ru, 2do2go.ru, antikvar.su, antikvariat74...
7
       [63.ru, deti-club.ru, k-agent.ru, mail.rambler...
8
       [1tv.ru, aif.ru, allbanks.kz, auto.drom.ru, au...
9
       [auto.drom.ru, autorambler.ru, drom.ru, eva.ru...
10
       [6lib.ru, belogorck.ru, gazeta.ru, informio.ru...
11
                           [mail.rambler.ru, rambler.ru]
12
       [aeroflot.ru, id.rambler.ru, mail.rambler.ru, ...
13
       [1000-tovarov.ru, a-lpha.su, aenergetika.ru, a...
14
       [3-ndfl.com, citytraffic.ru, consultant.ru, co...
15
       [dni.ru, games.kanobu.ru, goodhouse.ru, id.ram...
16
       [98765432.www.nn.ru, aimfar.solution.weborama...
17
       [autorambler.ru, blagoveschensk.tiu.ru, consul...
18
       [1zagran.ru, 3-ndfl.info, 52.mobilfunk.ru, aif...
19
       [agroserver.ru, aimfar.solution.weborama.fr, a...
20
       [1prime.ru, afisha.ru, aif.ru, autorambler.ru,...
21
       [buhonline.ru, hi-tech.mail.ru, id.rambler.ru,...
22
       [a-russia.ru, adenium-doma.ru, autorambler.ru,...
23
       [apteka-ifk.ru, by-vitebsk.vedun.ru, id.ramble...
24
       [1tv.ru, 8634city.ru, aif.ru, allforchildren.r...
25
       [3dyuriki.com, mail.rambler.ru, news.rambler.r...
26
       [autorambler.ru, dni.ru, govoritmoskva.ru, inf...
27
       [2r.ru, 30.joblib.ru, abc2home.ru, aif-nn.ru, ...
28
       [17mkad.ru, 360.ru, artstudio-pro.ru, autoramb...
29
       [eadaily.com, family.rambler.ru, inforeactor.r...
19944
       [50.rjob.ru, 93job.ru, angarsk.careerist.ru, a...
19945
       [100bretelek.ru, 1zagran.ru, 2r.ru, 2trade.ru,...
       [mail.rambler.ru, new.tv.rambler.ru, onlyf.ws,...
19946
       [avtolitsey.jimdo.com, ax.do.am, bmwpark.ru, b...
19947
       [amgum.ru, assets.adobedtm.com, avtovzglyad.ru...
19948
19949
       [1bm.ru, 1lentanovostei.ru, 1prime.ru, 1svegie...
       [220blog.ru, aimfar.solution.weborama.fr, cons...
19950
19951
                           [mail.rambler.ru, rambler.ru]
       [aliexpreses.ru, autorambler.ru, badm11.ru, ba...
19952
19953
       [id.rambler.ru, iland.tv, mail.rambler.ru, new...
19954
       [job-mo.ru, lesorub44.ru, mail.rambler.ru, mo...
19955
       [aimfar.solution.weborama.fr, id.rambler.ru, m...
19956
       [football.ua, m.rambler.ru, mail-pda.rambler.r...
       [altshuller.ru, blog.liga.net, felbert.livejou...
19957
19958
       [babyplan.ru, kidbutik.com.ua, led-portal.ru, ...
19959
       [advego.com, advego.ru, ax.do.am, clubmed.ru, ...
19960
                          [futuland.ru, mail.rambler.ru]
19961
       [aif.ru, baruk.ru, expert.ru, id.rambler.ru, 1...
19962
       [id.rambler.ru, ilizium.com, mail.rambler.ru, ...
       [mail.rambler.ru, n-novgorod.carent.ru, paulz...
19963
       [football-shopping.ru, forum.sibnet.ru, id.ram...
19964
19965
       [career.ru, hh.ru, itkani.ru, mail.rambler.ru,...
19966
       [autorambler.ru, gazeta.ru, iarex.ru, jobinmos...
19967
       [mail.rambler.ru, ped-kopilka.ru, pevp.mos.ru,...
19968
       [glavap.ru, irn.ru, mail.rambler.ru, medikforu...
19969
       [akusherstvo.ru, cat.pet2me.com, domik3.ru, ge...
19970
       [free.drweb.ru, mail.rambler.ru, pevp.mos.ru, ...
       [afisha.ru, formulalubvi.com, gazeta.ru, hh.ru...
19971
```

19972 [kirrail.org, lenta.ru, mail.rambler.ru, rambl... 19973 [help.rambler.ru, mail.rambler.ru, realtymag.r...

	id	label	age
0	00000014A02348E701552980349FF01	4	0
1	00000014A10EA183BF8594A0B2AB201	4	0
2	000000014A4FE5C33A929D4C26943601	4	0
3	000000014B7BB9957784A9BC0AC9F401	3	0
4	000000014C7749F896D82C2B01E8B801	3	0
5	000000014CAD0728017D0850076EAA01	4	0
6	000000014CD445FDBD0B82AB03B7E601	4	0
7	000000014CE4E75679C7BAD4020FEA01	4	0
8	000000014D21FF3C0D847BEE0D309801	4	0
9	000000014D3ABB36375A07970C971401	4	0
10	000000014D98FA2EA7479FB404A03101	3	0
11	000000014DAE6C7C86332D11016BE501	3	0
12	000000014DD67EF27730CD2C0030D201	4	0
13	000000014DFED69C57CE072A04306601	4	0
14	000000014E083FE5A9DE149404617301	4	0
15	000000014E13029D28DD08A8000B8C01	4	0
16	000000014E130B625265210900274D01	4	0
17	000000014E1329B2352151A500573001	4	0
18	000000014E13344B1D9CD24D0015E201	3	0
19	000000014E136A81387C51A900B68B01	3	0
20	000000014E140852325D08B0008E5501	4	0
21	000000014E187ECE32BF08B102990B01	3	0
22	000000014E1C67067A1516A600059001	4	0
23	000000014E1C739F0CFD5FF60019F601	4	0
24	000000014E1C770911C947120010A201	4	0
25	000000014E1C79C5C12F05B300241B01	4	0
26	000000014E33F54E06E9DEA702372801	5	0
27	000000014E435E5B70122BC101D70901	3	0
28	000000014E4A5A8948B7064603A26401	4	0
29	000000014E4D2C4457D7F01E0246B301	5	0
19944	0638F71656D7CEF5000004FDEEBC7A01	3	0
19945	0638FAFD56F0F2780000054F2C61F601	3	0
19946	0638FF59570537E90000054C1FA89601	4	0
19947	0639030F5702861A000004DE6E0AA401	3	0
19948	06390A7756CDFA780000054394E69501	3	0
19949	06390B8C56DB281E0000055EDF179E01	4	0
19950	0639141856F22C3B00000558462EC601	3	0
19951	0639159456FD44EB000004D600DD9301	3	0
19952	0639173F56B8D37900006DE98701AE01	3	0
19953	063921985703CA6E0000053D0D9D7901	4	0
19954	0639220256FFF8B40000054CACA14601	3	0
19955	063924CE5705583F000051CC70B91C01	3	0
19956	0639258857056E3700006DBED3C0AB01	3	0
19957	0639276956F990FE000051E07F3A3401	4	0
19958	063927B456FD3587000004DEFFA3E601	2	0
19959	06392B7156DD422C000004DE5EF5EB01	3	0
19960	06392EEA5703F65D0000054731AE6401	3	0
19961	0639303257001D0A00000533C3FBF601	4	0
19962	063936205703E1740000055FAEDB8001	3	0

```
19963 0639370457049F390000053324988801
                                            3
                                                 0
19964 0639387E56F1821F0000053C9F63A701
19965 0639394D57041CC4000051B65788B001
                                            2
                                                 0
19966 06393957570236E400000555EC4A5201
                                            4
                                                 Λ
19967 06393B8756FBCE950000054B6CE7A501
                                            4
                                                 0
                                            4
                                                 0
19968 06393B8756FDFCB60000054B96091901
19969 06393B8756FE32ED000004DE11330B01
                                                 0
19970 06393B87570376CB000004D6801BDC01
                                                 0
19971 06393D555702D3B2000004DE774F1901
                                            3
                                                 0
19972 06394267570511A900000540C88F9201
19973 0639457C57020EB700006DD1885A0501
                                                 0
```

[19974 rows x 4 columns]

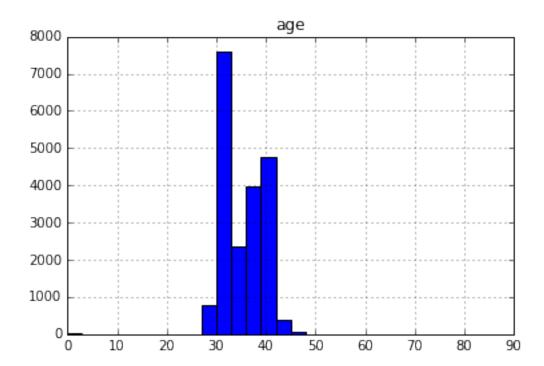
1.6 2nd level – k-means with several centroids

```
In [44]: from sklearn.cluster import KMeans
         from pandas import Index
         n_{of} clusters = [27, 4, 4, 6, 8, 50]
         start_age = [0, 27, 31, 35, 40, 49]
         for label in range(1, 7):
             df_subset = train_df[train_df["label"] == label]
             print(df_subset.shape)
             X_train_matrix, y_train = df_subset.loc[:, ["urls"]].as_matrix(), df_subset.loc[:, ["age"]]
               print(X_train_matrix)
               print(X_train_matrix.shape)
             \# X_train_matrix, y_train = train_df.loc[:, ["urls", "titles"]].as_matrix(), <math>train_df.loc[:]
             X_train = df_subset.urls.values.copy()
               print(X_train)
             for index in range(X_train_matrix.shape[0]):
                 X_train[index] = X_train_matrix[index][0]
         #
               print(X_train)
               print(X_train.shape)
               print(type(X_train))
             test_subset = urls_test_df[urls_test_df["label"] == label].urls
             if test_subset.shape[0] == 0:
                 continue
               print(test_subset)
         #
              print(test_subset.shape)
               print(test_subset.index)
             %time hw = HashingVectorizer(n_features=1000)
             %time X_train = hw.transform(X_train)
             %time km = KMeans(n_of_clusters[label - 1], n_jobs=-1)
             %time km.fit(X_train, y_train)
             test_subset_m = map(lambda x: ' '.join(x), test_subset)
             %time hw = HashingVectorizer(n_features=1000).fit(test_subset_m)
             test_subset_m = hw.transform(test_subset_m).todense()
             y_pred_subset = km.predict(test_subset_m)
               print(y_pred_subset)
               test_subset['age'] = y_pred_subset
             for index, data in test_subset.iteritems():
```

```
print(index)
                 urls_test_df.set_value(index, "age", y_pred_subset[g] + start_age[label - 1])
               print(urls_test_df.loc[3202, "age"])
         #
               km.predict()
(22226, 5)
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 15 \mus
CPU times: user 1.18 s, sys: 16.7 ms, total: 1.19 s
Wall time: 1.18 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 16 \mus
CPU times: user 777 ms, sys: 157 ms, total: 933 ms
Wall time: 15.6 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 56 \mus
(18969, 5)
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 13.1 \mus
CPU times: user 1.07 s, sys: 6.67 ms, total: 1.08 s
Wall time: 1.05 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 16 \mus
CPU times: user 733 ms, sys: 123 ms, total: 857 ms
Wall time: 4.77 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 57 \mus
(17358, 5)
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 12.9 \mus
CPU times: user 930 ms, sys: 10 ms, total: 940 ms
Wall time: 931 ms
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 29.1 \mus
CPU times: user 723 ms, sys: 137 ms, total: 860 ms
Wall time: 3.91 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 179 \mus
(18222, 5)
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 41 \mus
CPU times: user 1.04 s, sys: 3.33 ms, total: 1.05 s
Wall time: 1.03 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 28.8 \mus
CPU times: user 733 ms, sys: 133 ms, total: 867 ms
Wall time: 6.2 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 57.2 \mus
(18124, 5)
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 14.1 \mus
CPU times: user 1.09 s, sys: 6.67 ms, total: 1.1 s
```

```
Wall time: 1.08 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 16.9 \mu s
CPU times: user 743 ms, sys: 137 ms, total: 880 ms
Wall time: 8.89 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 56 \mus
(17328, 5)
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 12.9 \mu \mathrm{s}
CPU times: user 1.19 s, sys: 6.67 ms, total: 1.19 s
Wall time: 1.17 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 27.9 \mus
CPU times: user 750 ms, sys: 147 ms, total: 897 ms
Wall time: 26.8 s
CPU times: user 0 ns, sys: 0 ns, total: 0 ns
Wall time: 64.8 \mus
In [45]: print(urls_test_df.loc[3202, "age"])
11.0
```

In [50]: urls_test_df.hist(column="age", bins=30)

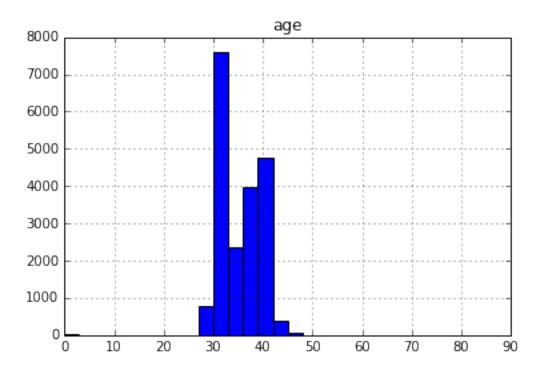


Out[50]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x7fa8648f9050>]], dtype=object)

1.7 Model testing

1.8 Solution Gathering

```
In [52]: urls_test_df = urls_test_df[['id', 'age']]
         urls_test_df.columns = ['Id', 'age']
In [53]: urls_test_df.head()
Out [53]:
                                          Ιd
                                              age
           000000014A02348E701552980349FF01
                                               39
         1
           000000014A10EA183BF8594A0B2AB201
                                               36
           000000014A4FE5C33A929D4C26943601
                                               36
         3 000000014B7BB9957784A9BC0AC9F401
                                               34
           000000014C7749F896D82C2B01E8B801
In [54]: random_sol = pd.read_csv('random_solution.csv')
         miss_idx = set(random_sol.Id.values) - set(urls_test_df.Id.values)
         miss_df = pd.DataFrame(zip(list(miss_idx), np.ones(len(miss_idx))))
         miss_df.columns = ['Id', 'age']
         miss_df.age = 30
In [55]: urls_test_df = urls_test_df.append(miss_df, ignore_index=True)
In [60]: urls_test_df.hist(column="age", bins=30)
Out[60]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x7fa8644a91d0>]], dtype=object)
```



```
In [57]: urls_test_df.to_csv('solution.csv', index=False)
In [58]: !wc -l solution.csv
19980 solution.csv
```